

1.简述下你是如何完成第一次挑战的。

（1）首先阅读第一次挑战文档，梳理整体任务目标、环境版本与交付物清单，明确需要部署 SGLang 推理服务、构造 workload、绘制流程图、完成概念问答并整理多份 PDF 文档上传至 GitHub 公开仓库。

（2）借助 AI 和官方文档，搭建 Ubuntu/WSL 环境，并在不同环境中配置指定版本的 SGLang 和 Ray，下载 Qwen/Qwq3-0.6B 模型，启动 SGLang 推理服务，发送一次推理请求。

（3）在理论阅读方面，先通过 AI 和视频了解大模型推理服务框架，然后借助 AI 翻译论文，遇到不懂概念结合官方文档和询问 AI，更快了解 KV Cache、RadixCache 等核心概念。

2. 你觉得哪部分工作最困难，你是如何克服这个困难的。

在我实验过程中，我觉得最难部分是部署环境和启动 SGLang 推理服务，在这一部分会遇见各种报错信息和版本不匹配以及版本矛盾等问题。我主要通过 AI 去排查错误地方，并在每一小步完成后及时检查安装是否成功版本是否正确。

3. 你觉得类似的从 0 到 1 的科研工作，需要包含哪些方面的研究，对你今后的科研工作有什么启发。

（1）阅读相关论文，分析现有方案的优缺点；

（2）对于新的想法需要通过实验验证；

（3）需要不断学习相关知识。

启发：

（1）调试报错也是科研的一部分，遇到问题要分析根源，不要轻易放弃；

（2）科研不能只看理论，要结合真实场景，多动手做实验。