

1. RadixAttention / RadixCache 解决多调用场景前缀 KV Cache 重复计算问题。在运行时自动系统化实现 KV 缓存复用，SGLang 在基数树中保存提示与生成结果对应的 KV 缓存，高效完成前缀匹配、复用、插入、驱逐。实现 LRU 淘汰策略与缓存感知调度，提升缓存命中率。

2. page-sized KV cache 对应 Scheduler 调度器，prefix reuse 对应 ModelWorker GPU 前向计算。

3.

（1）vLLM 的 PagedAttention 将 KV cache 切为固定大小的物理 block，按需分配 block，请求结束按块回收，消除 KV Cache 显存碎片，提升 GPU 显存利用率，放大连续批处理的并发上限。

（2）联系与差异：RadixAttention 底层存储同样基于 paged KV，和 PagedAttention 共享同一套“分页存储”基础思想。但是 RadixAttention 在 paged KV 之上，加一层基数树（Radix Tree），解决跨请求前缀 KV 重复计算。